

ফাইনাল ডিফেন্স প্রস্তুতি গাইড

Explainable Heterogeneous GNN with Severity-Weighted Edges for Clinical Symptom-Disease Prediction

IEEE গবেষণাপত্রের সম্পূর্ণ বাংলা ব্যাখ্যা

সম্পূর্ণ সেকশন বিশ্লেষণ | মূল সূত্র | ডিফেন্স প্রস্তুতির প্রস্তুতি

Knowledge Engineering Final Project | Graph Neural Network Symptom Checker | 2026

📄 বিষয়বস্তু সূচি (Table of Contents)

- ১ সার-সংক্ষেপ (Abstract) — গবেষণাটি কী নিয়ে?
- ২ ভূমিকা (Introduction) — কেন এই গবেষণা দরকার?
- ৩ সম্পর্কিত কাজ (Related Work) — আগে কী হয়েছে?
- ৪ পদ্ধতি (Methodology) — কীভাবে তৈরি করা হয়েছে?
- ৫ পরীক্ষা-নিরীক্ষা ও ফলাফল (Experiments & Results)
- ৬ আলোচনা (Discussion) — ফলাফলের গভীর বিশ্লেষণ
- ৭ উপসংহার ও ভবিষ্যৎ কাজ (Conclusion & Future Work)
- ★ মূল পরিভাষা ও ডিফেন্স কৌশল



সার-সংক্ষেপ (Abstract)

Abstract — গবেষণার সংক্ষিপ্ত পরিচয়



Abstract কী?

Abstract হলো পুরো গবেষণাপত্রের সংক্ষিপ্ত সারসংক্ষেপ। এটি সাধারণত ১৫০–২৫০ শব্দের মধ্যে থাকে এবং এতে গবেষণার সমস্যা, পদ্ধতি, এবং ফলাফল একসাথে উপস্থাপন করা হয়। যেকোনো পাঠক Abstract পড়েই বুঝতে পারেন গবেষণাটি কী নিয়ে।

▶ এই Abstract-এ কী বলা হয়েছে?

- ১ সমস্যা চিহ্নিতকরণ:** আধুনিক ডিজিটাল স্বাস্থ্যসেবায় Symptom Checker (লক্ষণ পরীক্ষক) একটি গুরুত্বপূর্ণ হাতিয়ার। কিন্তু বেশিরভাগ বিদ্যমান পদ্ধতি রোগীর লক্ষণগুলোকে স্বাধীন (independent) ডেটা হিসেবে বিবেচনা করে, যা চিকিৎসাবিজ্ঞানের বাস্তবতার সাথে সামঞ্জস্যপূর্ণ নয়।
- ২ প্রস্তাবিত সমাধান:** এই গবেষণায় একটি **H-GraphConv (Heterogeneous Graph Convolutional Network)** তৈরি করা হয়েছে যেখানে রোগ ও লক্ষণের মধ্যে সম্পর্কে **Graph** হিসেবে উপস্থাপন করা হয়। প্রতিটি সংযোগের (edge) ওজন লক্ষণের সম্ভাবনা ও গাণিত্য দিয়ে নির্ধারিত।
- ৩ ডেটাসেট:** Columbia University-র Disease-Symptom Knowledge Base থেকে প্রাপ্ত **৪,৯২০টি রোগীর রেকর্ড, ৪১টি রোগ এবং ১৩১টি লক্ষণ** ব্যবহার করা হয়েছে।
- ৪ ফলাফল:** মডেলটি ২০০ epoch-এ training loss ১০৪.৬২ থেকে ০.২৭৯-তে নেমে এসেছে। মূল পারফরম্যান্স মেট্রিক্স: Accuracy 95.3%, F1-Score 95.7%, AUC-ROC 0.9412।
- ৫ XAI মডিউল:** প্রতিটি ভবিষ্যদ্বাণীর জন্য কোন লক্ষণ কতটুকু গুরুত্বপূর্ণ ছিল তা গণিতগতভাবে সঠিকভাবে ব্যাখ্যা করা হয়।



ডিফেন্সে যা বলবেন

- আমাদের গবেষণার মূল অবদান হলো দুটি: (১) Severity-Weighted Graph এবং (২) Mathematically Exact XAI

- আমরা একটি Knowledge Graph-ভিত্তিক clinical diagnosis system তৈরি করেছি যা traditional ML-এর চেয়ে বেশি কার্যকর।
- এই system Streamlit-এ deploy করা হয়েছে, তাই এটি real-time ব্যবহারের উপযোগী।



ভূমিকা (Introduction)

Introduction — কেন এই গবেষণা করা হলো?

► A. পটভূমি ও প্রেরণা (Background & Motivation)

বিশ্বের স্বাস্থ্যসেবা ব্যবস্থায় ডিজিটাল রূপান্তর ঘটছে দ্রুতগতিতে। Electronic Health Records (EHR), wearable sensor, এবং mobile অ্যাপ থেকে প্রচুর পরিমাণে ক্লিনিক্যাল ডেটা তৈরি হচ্ছে। কৃত্রিম বুদ্ধিমত্তা (AI), বিশেষ করে Deep Learning, এই ডেটা থেকে অর্থপূর্ণ pattern খুঁজে বের করতে পারে।

🔑 মূল সমস্যা কী?

রোগের লক্ষণগুলো পরস্পর সম্পর্কিত। উদাহরণ: "উচ্চ জ্বর + কাঁপুনি" এবং "উচ্চ জ্বর + শ্বাসকষ্ট" — দুটোতেই উচ্চ জ্বর আছে, কিন্তু রোগ ভিন্ন! পুরনো Machine Learning পদ্ধতি (SVM, Random Forest, Feed-forward Neural Network) প্রতিটি লক্ষণকে আলাদাভাবে দেখে, তাদের মধ্যে সম্পর্ক উপেক্ষা করে। এটাই মূল সমস্যা।

Knowledge Engineering এই সমস্যার সমাধান দেয়। Medical domain-কে একটি **Knowledge Graph (KG)** হিসেবে উপস্থাপন করা হয় যেখানে nodes হলো রোগ ও লক্ষণ, এবং edges হলো তাদের মধ্যে সম্পর্ক। এর উপরে Graph Neural Network (GNN) চালালে topology থেকে শিক্ষা নিতে পারে।

► B. সমস্যার বিবৃতি (Problem Statement)

বিদ্যমান GNN-ভিত্তিক diagnostic system-এ দুটি মূল দুর্বলতা রয়েছে:

#	সমস্যা	বিস্তারিত ব্যাখ্যা
১	Binary Edge Problem	বিদ্যমান মডেলগুলো রোগ-লক্ষণ সম্পর্কে শুধু 0 বা 1 (আছে বা নেই) দিয়ে দেখায়। কিন্তু Malaria-তে জ্বর ৯৫% ক্ষেত্রে আসে , আর Arthritis-এ জ্বর মাত্র ৪০% ক্ষেত্রে — এই পার্থক্য ধরা যায় না।
২	Explainability Gap	আধুনিক GNN "black box" — কেন এই রোগ predict করা হলো তা বোঝা যায় না। ডাক্তার ও নিয়ন্ত্রক সংস্থা (regulator) কারণ না জানলে AI-এর পরামর্শ মানতে পারে না।

► C. প্রস্তাবিত সমাধান ও অবদান (Contributions)

Contribution 1

Severity-Weighted Graph তৈরি

Contribution 2

H-GraphConv Architecture

Contribution 3

XAI Attribution Module

Contribution 4

Streamlit Web App Deploy

🎯 ডিফেন্সে যা বলবেন

- "Traditional ML পদ্ধতি feature independence assume করে, কিন্তু medical symptom-এ এটা সত্য নয়।"
- "আমরা Knowledge Graph ব্যবহার করেছি কারণ এটি রোগ-লক্ষণের relational structure সঠিকভাবে ধরতে পারে।"
- "আমাদের দুটি মূল contribution: weighted edges এবং mathematically exact XAI"

II

সম্পর্কিত কাজ (Related Work)

Literature Review — আগে কী গবেষণা হয়েছে?

 Related Work কেন গুরুত্বপূর্ণ?

Related Work বিভাগে আমরা দেখাই যে আমাদের আগে কী কী গবেষণা হয়েছে এবং সেগুলোর কোথায় সীমাবদ্ধতা রয়েছে। এটি আমাদের গবেষণার প্রয়োজনীয়তা প্রমাণ করে।

 A. Traditional ML & Deep Learning (পেপার ১-৫)

এই বিভাগে ৫টি গুরুত্বপূর্ণ গবেষণা বিশ্লেষণ করা হয়েছে:

লেখক	কাজ	সীমাবদ্ধতা
Esteva et al.	Deep Learning দিয়ে medical image diagnosis	শুধু image, symptom না
Topol (2019)	AI vs Human doctor comparison	Tabular data, graph না
Rajkomar et al.	EHR থেকে mortality prediction	Feature independence assumed
Chen et al.	Clinical classifier-এ discrimination	Relational structure ignore
Obermeyer et al.	Health algorithm-এ racial bias	Non-ontological approach

 সকলের একই সীমাবদ্ধতা

উপরের সব গবেষণাই symptom-কে tabular (ছকের মতো) ডেটা হিসেবে ব্যবহার করেছে। তারা লক্ষণগুলোর পারস্পরিক সম্পর্ক (relational structure) মডেল করতে পারেনি।

 B. Knowledge Graph & Medical Ontology (পেপার ৬-১০)

Knowledge Graph নিয়ে গবেষণায় দেখা গেছে static KG ডেটা সংরক্ষণে ভালো, কিন্তু নতুন রোগীর অসম্পূর্ণ লক্ষণ দিয়ে prediction করতে পারে না। এর জন্য GNN দরকার।

► C. GNN in Healthcare (পেপার ১১–১৫)

Sun et al. [15] হলো আমাদের সবচেয়ে কাছের গবেষণা — তারা GCN দিয়ে disease-symptom link predict করেছে, কিন্তু **binary, unweighted edge** ব্যবহার করেছে। আমরা এখানেই নতুন কিছু যোগ করেছি: severity-weighted edge।

► D. Explainable AI (পেপার ১৬–২০)

XAI গবেষণায় দেখা যায় SHAP, LIME, GNNExplainer সব approximation-ভিত্তিক — অর্থাৎ exact নয়। আমাদের Latent Feature Attribution method mathematically exact।

★ গবেষণার ফাঁক (Research Gap)

কোনো বিদ্যমান গবেষণায় একসাথে: (১) clinically grounded weighted edges + (২) mathematically exact XAI — দুটোই নেই। এই ফাঁকটি আমাদের গবেষণা পূরণ করেছে।

🎯 ডিফেন্সে যা বলবেন

- আমরা ২০টি পেপার ৪টি থিমে বিশ্লেষণ করেছি এবং একটি স্পষ্ট research gap খুঁজে পেয়েছি।
- Sun et al. [15] আমাদের সবচেয়ে কাছের পূর্ববর্তী কাজ, কিন্তু তারা weighted edge ব্যবহার করেনি।
- আমাদের XAI approach perturbation-based method-এর চেয়ে superior কারণ এটি exact।



পদ্ধতি (Methodology)

System Methodology — কীভাবে System তৈরি করা হলো?

► A. ডেটাসেট ও Graph নির্মাণ

১. ডেটা কোথা থেকে এসেছে?

Columbia University-এর Disease-Symptom Knowledge Base থেকে দুটি CSV ফাইল ব্যবহার করা হয়েছে:

- **dataset.csv** — ৪,৯২০ রোগীর রেকর্ড (৪৬টি রোগ, ৬৩৬টি লক্ষণ)
- **Symptom-severity.csv** — প্রতিটি লক্ষণের clinical গুরুত্ব স্কোর (১-৭)

২. Edge Weight কীভাবে নির্ণয় করা হয়?

📐 মূল সূত্র (Equation 1) — সবচেয়ে গুরুত্বপূর্ণ!

$$W_{d,s} = P(s | d) \times \text{Severity}(s)$$

যেখানে: $P(s|d)$ = রোগ d-তে লক্ষণ s-এর conditional probability

Severity(s) = লক্ষণ s-এর clinical গুরুত্ব (১ থেকে ৭)

🔑 উদাহরণ দিয়ে বুঝুন

- Malaria-তে জ্বর (fever): $P = 0.95$, Severity = 5 $\rightarrow W = 4.75$ (বেশি weight)
- Arthritis-এ জ্বর: $P = 0.40$, Severity = 5 $\rightarrow W = 2.00$ (কম weight)
- এইভাবে model বুঝতে পারে কোন রোগে কোন লক্ষণ বেশি গুরুত্বপূর্ণ।

৩. Heterogeneous Graph কীভাবে তৈরি?

Graph-এ দুই ধরনের node এবং দুই ধরনের edge রয়েছে:

উপাদান

বিবরণ

সংখ্যা

Disease Node	রোগের নোড (identity matrix I_{41})	৪১টি
Symptom Node	লক্ষণের নোড (identity matrix I_{131})	১৩১টি
exhibits edge	রোগ → লক্ষণ	E সংখ্যক
rev_exhibits edge	লক্ষণ → রোগ (reverse)	E সংখ্যক

প্রতিটি node-এর initial feature হলো **identity matrix** — অর্থাৎ প্রতিটি রোগ ও লক্ষণ একটি unique one-hot vector। সব discriminative learning graph topology থেকে শেখা হবে।

► B. Model Architecture (H-GraphConv)

১. GraphConv অপারেটর

$$h_v^{(l+1)} = W_{\text{root}} \cdot h_v^{(l)} + W_{\text{neigh}} \cdot \sum w_{u,v} \cdot h_u^{(l)}$$

h_v = node v-এর embedding | W_{root} = নিজের জন্য weight matrix

W_{neigh} = প্রতিবেশীর জন্য weight matrix | $w_{u,v}$ = edge weight (আমাদের $W_{d,s}$)

🔑 GraphConv কেন GCNConv-এর চেয়ে ভালো?

GraphConv সরাসরি edge_weight টেনসর গ্রহণ করতে পারে। GCNConv পারে না। তাই আমাদের severity-weighted edge ব্যবহার করার জন্য GraphConv অপরিহার্য।

২. to_hetero() — Heterogeneous Conversion

to_hetero(GNN, metadata, aggr='sum') কী করে?

- Graph-এর সব node type ও edge type দেখে
- প্রতিটি edge type-এর জন্য আলাদা GraphConv weight matrix তৈরি করে
- এটি R-GCN (Relational GCN) এর সমতুল্য

৩. Input Projection

$$z_d = W_{\text{dis}} \cdot I_{[d]} \in \mathbb{R}^{64} \quad z_s = W_{\text{sym}} \cdot I_{[s]} \in \mathbb{R}^{64}$$

Disease ও Symptom নোডের ভিন্ন মাত্রাকে (41 ও 131) একই 64-মাত্রিক space-এ আনা হয়

8. সম্পূর্ণ Architecture

Layer	Type	Input → Output	Parameters
disease_lin	Linear	41 → 64	2,624
symptom_lin	Linear	131 → 64	8,384
conv1_exhibits	GraphConv	64 → 64	8,256
conv1_rev_exhibits	GraphConv	64 → 64	8,256
conv2_exhibits	GraphConv	64 → 64	8,256
conv2_rev_exhibits	GraphConv	64 → 64	8,256
মোট Trainable Parameters			44,032

► C. Link Prediction Training

Training কীভাবে কাজ করে? মডেলটি শেখে কোন রোগ-লক্ষণ pair আসলে সংযুক্ত (positive) আর কোনটা নয় (negative)।

$$\hat{y}_{ij} = e_i \cdot e_j = \sum E_{i,k} \cdot E_{j,k} \quad (k=1 \text{ to } 64)$$

Dot Product: দুটি embedding-এর similarity পরিমাপ করে

$$\text{Loss} = \text{BCEWithLogitsLoss}(\hat{y}, y)$$

Binary Cross-Entropy Loss — positive edge-এর জন্য score বেশি, negative-এর জন্য কম হওয়া উচিত

🔑 Negative Sampling কী?

প্রতিটি real edge (positive) এর বিপরীতে একটি random non-existing edge (negative) তৈরি করা হয়। এইভাবে model শেখে real connection এবং random connection-এর মধ্যে পার্থক্য। Ratio: 1:1

► D. Patient Inference (রোগী Diagnosis)

নতুন রোগী লক্ষণ দিলে কীভাবে রোগ predict হয়?

১ Patient Profile Embedding:

$$e_p = (1/n) \sum e_{si}$$

রোগীর সব লক্ষণের embedding-এর গড় নেওয়া হয়

২ Disease Score:

$$\text{Score}(d) = \sigma(e_d \cdot e_p) \in [0, 1]$$

প্রতিটি রোগের embedding-এর সাথে patient embedding-এর dot product, তারপর sigmoid

৩ Top-k রোগ score অনুযায়ী ranked করে output দেওয়া হয়।

► E. Explainable AI — Latent Feature Attribution

★ এটি সবচেয়ে গুরুত্বপূর্ণ অংশ!

এই অংশটি আমাদের গবেষণার সবচেয়ে নতুন ও উদ্ভাবনী অবদান।

গণিতের মূল কৌশল:

$$e_d \cdot e_p = e_d \cdot (1/n \sum e_{si}) = (1/n) \sum (e_d \cdot e_{si})$$

Dot product-এর distributive property ব্যবহার করে prediction score-কে প্রতিটি লক্ষণের আলাদা contribution-এ ভাগ করা হয়

$$\text{Attribution}(s_i, D) = (1/n) \times (e_D \cdot e_{s_i})$$

লক্ষণ s_i রোগ D -এর prediction-এ কতটুকু ভূমিকা রেখেছে তার exact measure

XAI Property	বাংলায় অর্থ	আমাদের Method
Completeness	সব attribution যোগ করলে মোট score পাওয়া যাবে	✓ Exact (Eq. 10 থেকে)
Symmetry	একই লক্ষণ সবসময় একই attribution পাবে	✓ Embedding unique বলে
Sensitivity	অপ্রাসঙ্গিক লক্ষণের attribution = 0	✓ Dot product = 0 হলে

🔑 কেন এটি অনন্য?

- **SHAP, LIME, GNNExplainer** — approximation-ভিত্তিক, পরিবর্তনশীল ফলাফল
- **আমাদের method** — exact mathematical decomposition, deterministic (সবসময় একই ফলাফল)
- Clinical deployment-এ exact ও reproducible explanation নিয়ন্ত্রকদের জন্য অপরিহার্য

🎯 ডিফেন্স Methodology নিয়ে যা বলবেন

- "Edge weight formula $W = P(s|d) \times \text{Severity}(s)$ হলো আমাদের প্রথম মূল উদ্ভাবন।"
- "GraphConv ব্যবহার করেছি কারণ এটি edge_weight directly গ্রহণ করে।"
- "to_hetero() R-GCN-এর মতো কাজ করে — প্রতিটি edge type-এর জন্য আলাদা parameters।"
- "XAI-এ আমরা dot product-এর distributive property ব্যবহার করে exact decomposition করেছি।"
- "Training-এ negative sampling 1:1 ratio-তে করা হয়েছে।"

IV

পরীক্ষা-নিরীক্ষা ও ফলাফল (Experiments & Results)

Experiments — Model পরীক্ষার ফলাফল

A. Hyperparameter Configuration

Hyperparameter	বাংলায় অর্থ	মান
Hidden Channels	Hidden embedding-এর মাত্রা	64
GNN Layers	Graph convolution layer সংখ্যা	2
Optimizer	Gradient update পদ্ধতি	Adam
Learning Rate	শেখার গতি	0.01
Loss Function	Error পরিমাপ	BCEWithLogitsLoss
Epochs	পূর্ণ training cycle	200
Negative Ratio	Positive:Negative edge	1:1

B. Training Loss Convergence (Loss কমানোর ধারা)

Epoch	Training Loss	ব্যাখ্যা
1	104.62	শুরুতে high — severity weight-এর কারণে বড় embedding magnitude
20	28.41	দ্রুত কমেছে
40	8.93	—
80	2.17	—
120	0.89	—

160 0.44 —

200 0.279 99.7% হ্রাস — অত্যন্ত সফল convergence!**🔑 Convergence কেন গুরুত্বপূর্ণ?**

Loss যদি smooth-ভাবে কমে (না ওঠানামা করে), তাহলে বোঝা যায় model stable এবং gradient explosion বা vanishing হয়নি। ১০৪.৬২ থেকে ০.২৭৯ — এটি ৯৯.৭% হ্রাস, যা মডেলের শক্তিশালী learning ক্ষমতা প্রমাণ করে।

► C. মূল পারফরম্যান্স মেট্রিক্স

মেট্রিক্সের সংজ্ঞা ও সূত্র:

Metric	বাংলায় অর্থ	সূত্র
Accuracy	সামগ্রিক নির্ভুলতা	$(TP+TN)/(TP+TN+FP+FN)$
Precision	Positive prediction-এর নির্ভুলতা	$TP/(TP+FP)$
Recall	আসল Positive ধরার ক্ষমতা	$TP/(TP+FN)$
F1-Score	Precision ও Recall-এর সমন্বয়	$2 \times P \times R / (P+R)$
AUC-ROC	Discrimination ক্ষমতা (0.5–1.0)	ROC curve-এর নিচের area

🔑 Confusion Matrix থেকে হিসাব

TP=912, TN=847, FP=43, FN=38 (মোট test: 1,840)

$$\text{Accuracy} = (912+847)/(912+847+43+38) = 1759/1840 = 95.6\%$$

$$\text{Precision} = 912/(912+43) = 95.5\%$$

$$\text{Recall} = 912/(912+38) = 96.0\%$$

$$\text{F1} = 2 \times 0.955 \times 0.960 / (0.955 + 0.960) = 95.7\%$$

Comparative Performance:**► D. ROC Curve বিশ্লেষণ**

ROC (Receiver Operating Characteristic) Curve হলো একটি graph যেখানে:

- X-axis: False Positive Rate ($FPR = FP/(FP+TN)$)
- Y-axis: True Positive Rate ($TPR/Recall = TP/(TP+FN)$)

🔑 AUC-ROC = 0.9412 মানে কী?

- AUC = 0.50 → Random guessing (কোনো discrimination নেই)
- AUC = 1.00 → Perfect classifier
- AUC = **0.9412** → আমাদের model অত্যন্ত ভালো! ৯৪.১২% সময় সঠিকভাবে positive এবং negative edge আলাদা করতে পারে।

- Binary GCN (0.921) থেকে ২.০% বেশি — weighted edge-এর সুস্পষ্ট উপকার।

► E. Diagnostic Inference উদাহরণ

Input Symptom	Top-1 Prediction	Top-2	Top-3
উচ্চজ্বর, কাঁপুনি, ঘাম	Malaria (≥ 0.85)	Dengue	Typhoid
চুলকানি, চর্মরোগ, জন্ডিস	Hepatitis B (≥ 0.78)	Hepatitis C	Hepatitis A
গিঁটে ব্যথা, ফোলা	Arthritis (≥ 0.82)	Osteoarthritis	Rheumatoid
কাশি, শ্বাসকষ্ট, বুকে ব্যথা	Pneumonia (≥ 0.75)	Tuberculosis	Asthma

► F. XAI Attribution Case Study

Case 1 — Malaria: Input: {কাঁপুনি, উচ্চজ্বর}

Attribution(উচ্চজ্বর) $\gg$ Attribution(কাঁপুনি) — কারণ Malaria-তে জ্বরের prevalence $>90\%$, কাঁপুনির $\sim 65\%$ ।

Case 2 — Hepatitis B: Input: {চুলকানি, চর্মরোগ, জন্ডিস, পেটব্যথা}

Attribution(জন্ডিস) সর্বোচ্চ — কারণ জন্ডিস liver disease-এর pathognomonic sign (নিশ্চিত চিহ্ন)।

🔗 ডিফেন্সে Results নিয়ে যা বলবেন

- "99.7% loss reduction proves model stability and successful learning."
- "AUC-ROC 0.9412 মানে model 94% এর বেশি সময় সঠিকভাবে discriminate করতে পারে।"
- "Binary GCN-এর তুলনায় +7.1% Accuracy এবং +8.7% F1 — weighted edge-এর সরাসরি উপকার।"
- "Confusion Matrix: TP=912, TN=847 — model দুটি class-ই ভালোভাবে চেনে।"

- "XAI attribution clinically meaningful — জন্ডিস সঠিকভাবে সর্বোচ্চ attribution পেয়েছে Hepatitis B-তে।"



আলোচনা (Discussion)

Discussion — ফলাফলের গভীর বিশ্লেষণ ও সীমাবদ্ধতা

► A. Severity-Weighted Edge-এর গুরুত্ব

Unweighted graph-এ প্রতিটি লক্ষণ সমান গুরুত্ব পায়। ফলে model "হলমার্ক লক্ষণ" (যা রোগের সবচেয়ে নির্ভরযোগ্য চিহ্ন) এবং "আনুষঙ্গিক লক্ষণ" (যা ঘটনাক্রমে আসে) পার্থক্য করতে পারে না।

Weighted formulation-এ GraphConv উচ্চ weight-এর edge থেকে বেশি তথ্য নেয় এবং নিম্ন weight-এর edge থেকে কম। ফলে শেখা embedding clinically সঠিক।

পরিমাণগত প্রমাণ: Binary GCN-এর তুলনায় Accuracy +7.1%, F1-Score +8.7%।

► B. Latent Feature Attribution-এর গাণিতিক সঠিকতা

☆ অত্যন্ত গুরুত্বপূর্ণ বিষয়

আমাদের Attribution formula exact (সঠিক) — approximation নয়। SHAP ও LIME sampling করে estimate করে, তাই তাদের ফলাফল run-to-run পরিবর্তন হয়। আমাদের formula deterministic — একই input দিলে সবসময় একই explanation।

পদ্ধতি	ধরন	Reproducible?	Clinical উপযোগিতা
SHAP	Approximation (sampling)	না সবসময়	কম
LIME	Approximation (perturbation)	না	কম
GNNExplainer	Optimization-based	না	মাঝারি
আমাদের Attribution	Exact (closed-form)	হ্যাঁ, সবসময়	সর্বোচ্চ

► C. সীমাবদ্ধতা (Limitations)

#	সীমাবদ্ধতা	বিস্তারিত
১	Synthetic Dataset	৪,৯২০ রেকর্ড knowledge base থেকে তৈরি — real patient encounter নয়। বাস্তবে noise, missing value এবং একসাথে একাধিক রোগ থাকতে পারে।
২	Single-Hop Reasoning	2-layer GNN শুধু 2-hop পর্যন্ত দেখতে পারে। Disease → Symptom → Anatomical Region → Treatment — এই ধরনের multi-hop reasoning সম্ভব নয়।
৩	No Temporal Modeling	রোগীর সময়ের সাথে পরিবর্তন (disease progression) ধরতে পারে না।
৪	Closed-World Assumption	Training graph-এ নেই এমন নতুন রোগ predict করা সম্ভব নয়।
৫	Severity Data	একটি knowledge base থেকে severity weight — বিভিন্ন জনগোষ্ঠী বা clinical context-এ ভিন্ন হতে পারে।

Limitations স্বীকার করা কেন জরুরি?

একটি ভালো গবেষণাপত্র সবসময় তার সীমাবদ্ধতা সংভাবে উল্লেখ করে। এটি গবেষণার বিশ্বাসযোগ্যতা বাড়ায় এবং ভবিষ্যৎ গবেষকদের পথ দেখায়।

ডিফেন্সে Discussion নিয়ে যা বলবেন

- "আমাদের weighted edge আসলে clinical knowledge encode করে — এটি শুধু technical trick নয়।"
- "আমাদের XAI method clinically deployable কারণ এটি deterministic এবং auditable।"
- "আমরা জানি dataset synthetic — তাই future work-এ MIMIC-IV-এ validate করার পরিকল্পনা আছে।"
- যদি কেউ জিজ্ঞেস করে "এটি real hospital-এ কাজ করবে?" — বলুন: "এই কাজটি proof-of-concept, real deployment-এ validation দরকার।"

VI

উপসংহার ও ভবিষ্যৎ কাজ (Conclusion & Future Work)

Conclusion — গবেষণার সমাপ্তি ও ভবিষ্যৎ পরিকল্পনা

▶ A. উপসংহার

এই গবেষণায় সফলভাবে একটি **Knowledge Engineering framework** তৈরি এবং যাচাই করা হয়েছে যা clinical symptom checking-কে ব্যাখ্যাযোগ্য (explainable) ও graph-ভিত্তিক করে তোলে।

★ মূল অর্জন সমূহ

- ✓ Heterogeneous Bipartite Knowledge Graph with Severity-Weighted Edges তৈরি
- ✓ Loss: 104.62 → 0.279 (99.7% reduction) — smooth convergence প্রমাণিত
- ✓ Accuracy 95.3%, F1 95.7%, AUC-ROC 0.9412
- ✓ Mathematically exact XAI: Completeness, Symmetry, Sensitivity satisfied
- ✓ Streamlit web app-এ deploy: real-time diagnosis + XAI + sub-graph viz
- ✓ দুটি research gap বন্ধ: weighted edges + exact XAI

▶ B. ভবিষ্যৎ কাজ (Future Work)

#	দিকনির্দেশনা	বিস্তারিত
১	Multi-Type Graph	Anatomical Region, Lab Test, Medication node যোগ করে multi-hop reasoning
২	Real Clinical Data	MIMIC-IV, eICU dataset-এ train ও test
৩	Federated Learning	একাধিক hospital-এর data একত্রে privacy রক্ষা করে train করা

৪	LLM + KG Hybrid	Natural language-এ symptom input দিতে পারা ও plain language-এ explanation
৫	Clinical Trial	বাস্তব hospital-এ deploy করে doctor decision-making efficiency পরিমাপ

ডিফেন্সে Conclusion নিয়ে যা বলবেন

- "আমাদের গবেষণা দুটি নির্দিষ্ট research gap চিহ্নিত করেছে এবং উভয়ই পূরণ করেছে।"
- "ফলাফলে দেখা গেছে weighted edge ব্যবহার করলে unweighted-এর চেয়ে উল্লেখযোগ্যভাবে ভালো performance পাওয়া যায়।"
- "LLM + KG integration হলো সবচেয়ে প্রতিশ্রুতিশীল ভবিষ্যৎ গবেষণার দিক।"



মূল পরিভাষা অভিধান

Key Terms Glossary — ডিফেন্সে যে শব্দগুলো জানতে হবে

Knowledge Graph (KG)

জ্ঞান-সম্পর্ক মানচিত্র: entities (node) ও তাদের মধ্যে সম্পর্ক (edge)-এর নেটওয়ার্ক

Heterogeneous Graph

বিষমজাতীয় গ্রাফ: একাধিক ধরনের node ও edge বিশিষ্ট গ্রাফ

Bipartite Graph

দ্বি-লম্বীয় গ্রাফ: দুটি স্বতন্ত্র node-গ্রুপ (রোগ ও লক্ষণ) বিশিষ্ট গ্রাফ

Message Passing

বার্তা পাঠানো: প্রতিবেশী node থেকে তথ্য সংগ্রহের প্রক্রিয়া

Link Prediction

সংযোগ পূর্বানুমান: নতুন edge exist করবে কিনা তা predict করা

Embedding

সংখ্যাসারণি: node/entity-কে real number vector-এ রূপান্তর

Negative Sampling

নেতিবাচক নমুনা: non-existing edge তৈরি করা training-এর জন্য

Dot Product

বিন্দু গুণফল: দুই vector-এর similarity measure

Sigmoid Function

সিগময়েড: যেকোনো সংখ্যাকে 0-1 রেঞ্জে নিয়ে আসে

BCEWithLogitsLoss

Binary Cross Entropy: binary classification-এর loss function

XAI (Explainable AI)

ব্যাখ্যাযোগ্য AI: কেন এই prediction করল তা মানুষকে বোঝানো

Attribution

অবদান পরিমাপ: প্রতিটি feature কতটুকু prediction-এ ভূমিকা রেখেছে

AUC-ROC

ROC Curve-এর নিচের এলাকা: ১-এর কাছাকাছি হলে ভালো

Convergence

অভিসরণ: training loss ধীরে ধীরে কমে stable হওয়া

to_hetero()

PyG function: homogeneous GNN-কে heterogeneous-এ রূপান্তর

GraphConv

PyG operator: edge_weight সহ weighted aggregation করে

CDSS

Clinical Decision Support System:
চিকিৎসক সিদ্ধান্তে সহায়তাকারী AI

Conditional Probability $P(s|d)$

শর্তযুক্ত সম্ভাবনা: রোগ d দেওয়া থাকলে লক্ষণ s -
এর সম্ভাবনা



প্রত্যাশিত ডিফেন্স প্রশ্ন ও উত্তর

Expected Defense Questions & Answers

▶ প্রশ্ন ১: GNN কেন ব্যবহার করলেন, traditional ML কেন নয়?

✓ উত্তর

Traditional ML (SVM, Random Forest) প্রতিটি feature স্বাধীনভাবে দেখে। কিন্তু medical symptom পরস্পর সম্পর্কিত — "জ্বর + কাঁপুনি" ভিন্ন রোগ, "জ্বর + শ্বাসকষ্ট" ভিন্ন রোগ। GNN graph topology ব্যবহার করে এই relational structure capture করতে পারে।

▶ প্রশ্ন ২: Edge weight কীভাবে নির্ণয় করলেন?

✓ উত্তর

$W(d,s) = P(s|d) \times \text{Severity}(s)$ । $P(s|d)$ হলো dataset থেকে গণনা করা conditional probability, Severity হলো Columbia University-র clinical severity table থেকে নেওয়া (1-7 স্কেল)।

▶ প্রশ্ন ৩: to_hetero() কী করে?

✓ উত্তর

PyTorch Geometric-এর to_hetero() function একটি homogeneous GNN-কে heterogeneous-এ convert করে। এটি প্রতিটি edge type-এর জন্য আলাদা weight matrix তৈরি করে। এটি R-GCN-এর মতো কাজ করে।

▶ প্রশ্ন ৪: XAI কীভাবে কাজ করে? কেন এটি approximate নয়?

✓ উত্তর

Dot product-এর distributive property: $e_d \cdot (1/n \sum e_{si}) = (1/n) \sum (e_d \cdot e_{si})$ ।
এই algebraic identity ব্যবহার করে prediction score সঠিকভাবে প্রতিটি লক্ষণের contribution-এ ভাগ করা যায় — কোনো approximation নেই।

▶ প্রশ্ন ৫: প্রথমে loss 104.62 কেন এত বেশি ছিল?

✓ উত্তর

Edge weight $W(d,s) = P \times \text{Severity}$ সর্বোচ্চ $1.0 \times 7 = 7.0$ হতে পারে। বড় edge weight থেকে message passing-এ বড় embedding magnitude তৈরি হয়, ফলে dot product score বড় হয়, তাই initial loss বেশি। কিন্তু GraphConv-এর আলাদা root ও neighbor weight matrix এটি সামলাতে পারে এবং smooth convergence দেয়।

▶ প্রশ্ন ৬: এই system কি real hospital-এ deploy করা সম্ভব?

✓ উত্তর

বর্তমান কাজটি proof-of-concept। Real deployment-এর জন্য: (১) Real EHR data (MIMIC-IV) দিয়ে validate করতে হবে, (২) Medical regulatory approval দরকার, (৩) Federated learning দিয়ে privacy নিশ্চিত করতে হবে। Future work-এ এই পরিকল্পনা উল্লেখ আছে।

▶ প্রশ্ন ৭: Negative sampling কেন দরকার?

✓ উত্তর

Link prediction-এ শুধু positive edge দিয়ে train করলে model সবকিছুকে positive বলে শিখবে। Negative edge যোগ করলে model শেখে কোনটি real connection, কোনটি নয়। আমরা 1:1 ratio ব্যবহার করেছি।

▶ প্রশ্ন ৮: AUC-ROC ০.৯৪১২ কি যথেষ্ট ভালো?

 উত্তর

হ্যাঁ। Medical AI-এ সাধারণত AUC > 0.90 হলে "excellent" হিসেবে বিবেচনা করা হয়।
আমাদের 0.9412 এই threshold পার করে। তুলনামূলকভাবে Binary GCN = 0.921,
Random Forest = 0.871, SVM = 0.831।

 সম্পূর্ণ গবেষণার এক নজর সারসংক্ষেপ

গবেষণার মূল লক্ষ্য

**Explainable GNN-ভিত্তিক Symptom
Checker তৈরি**

মূল উদ্ভাবন

**Severity-Weighted Edge + Exact XAI
Attribution**

ডেটাসেট

৪,৯২০ রেকর্ড | ৪৬ রোগ | ১৩৬ লক্ষণ

Model Architecture

**2-Layer H-GraphConv | ৪৪,০৩২
Parameters**

Accuracy

95.3% (Binary GCN: 88.2%)

F1-Score

**95.7% | Precision: 95.5% | Recall:
96.0%**

AUC-ROC

0.9412 (Excellent — >0.90)

Deployment

Streamlit Web App (Real-time)

Loss Convergence

104.62 → 0.279 (99.7% ক্লাস, 200 epoch)

XAI Properties

**Completeness  | Symmetry  |
Sensitivity **

Research Gap Closed

Future Work (মূল)

Binary Edge Problem + Explainability
Gap

MIMIC-IV Validation + LLM-KG Hybrid

💡 ডিফেন্সে সাফল্যের মূলমন্ত্র

"আমাদের গবেষণা দুটি নির্দিষ্ট সমস্যা সমাধান করেছে: unweighted graph-এর সীমাবদ্ধতা এবং black-box prediction-এর অস্বচ্ছতা। প্রতিটি design decision-এর পেছনে clinical ও mathematical যুক্তি রয়েছে।"